课程介绍

- Elastic Stack简介
- Elasticsearch的介绍与安装
- Elasticsearch的快速入门
- Elasticsearch的核心讲解
- 中文分词

1、Elastic Stack简介

如果你没有听说过Elastic Stack，那你一定听说过ELK，实际上ELK是三款软件的简称，分别是Elasticsearch、Logstash、Kibana组成，在发展的过程中，又有新成员Beats的加入，所以就形成了Elastic Stack。所以说，ELK是旧的称呼，Elastic Stack是新的名字。

全系的Elastic Stack技术栈包括：

ElasticStack的组成

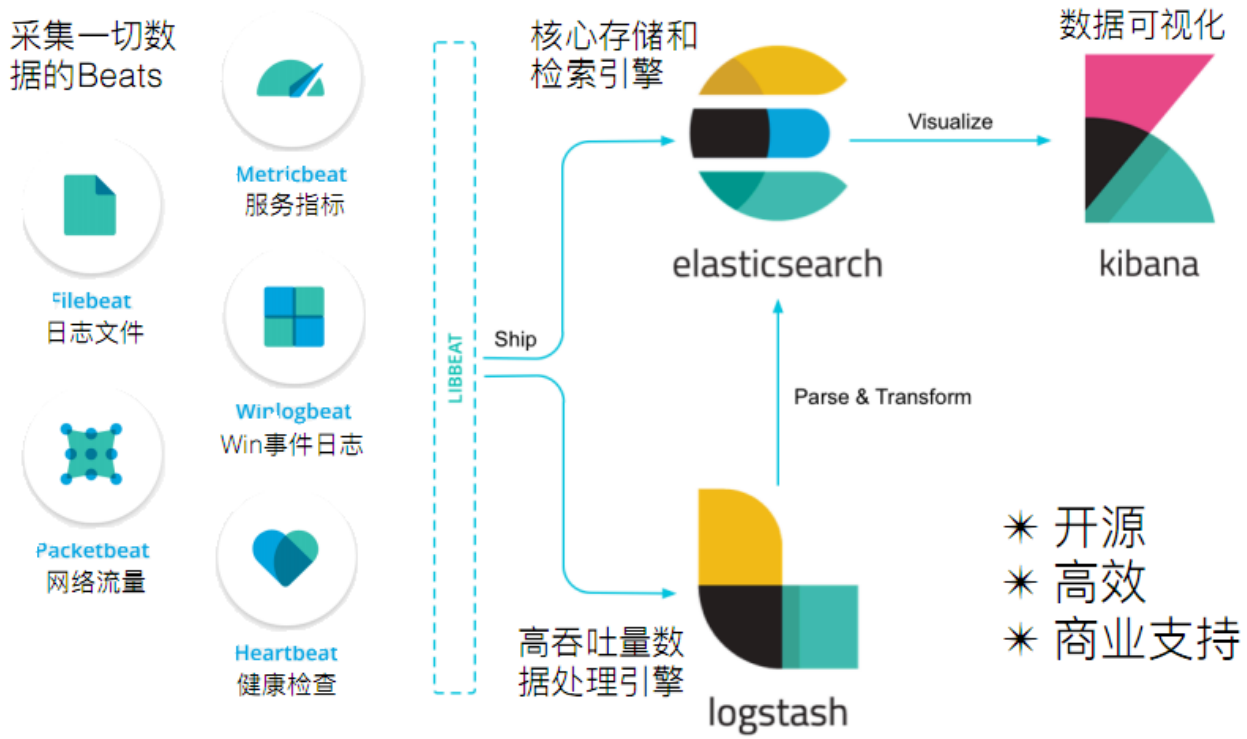

Elasticsearch

Elasticsearch 基于java，是个开源分布式搜索引擎，它的特点有：分布式，零配置，自动发现，索引自动分片，索引副本机制，restful风格接口，多数据源，自动搜索负载等。

Logstash

Logstash 基于java，是一个开源的用于收集,分析和存储日志的工具。

Kibana

Kibana 基于nodejs，也是一个开源和免费的工具，Kibana可以为 Logstash 和 ElasticSearch 提供的日志分析友好的 Web 界面，可以汇总、分析和搜索重要数据日志。

Beats

Beats是elastic公司开源的一款采集系统监控数据的代理agent，是在被监控服务器上以客户端形式运行的数据收集器的统称，可以直接把数据发送给Elasticsearch或者通过Logstash发送给Elasticsearch，然后进行后续的数据分析活动。

Beats由如下组成:

- Packetbeat：是一个网络数据包分析器，用于监控、收集网络流量信息，Packetbeat嗅探服务器之间的流量，解析应用层协议，并关联到消息的处理，其支 持ICMP (v4 and v6)、DNS、HTTP、Mysql、PostgreSQL、Redis、MongoDB、Memcache等协议；
- Filebeat：用于监控、收集服务器日志文件，其已取代 logstash forwarder；
- Metricbeat：可定期获取外部系统的监控指标信息，其可以监控、收集 Apache、HAProxy、MongoDB
- MySQL、Nginx、PostgreSQL、Redis、System、Zookeeper等服务；
- Winlogbeat：用于监控、收集Windows系统的日志信息；

2、Elasticsearch

2.1、简介

ElasticSearch是一个基于Lucene的搜索服务器。它提供了一个分布式多用户能力的全文搜索引擎，基于RESTful web接口。Elasticsearch是用Java开发的，并作为Apache许可条款下的开放源码发布，是当前流行的企业级搜索引擎。设计用于云计算中，能够达到实时搜索，稳定，可靠，快速，安装使用方便。

我们建立一个网站或应用程序，并要添加搜索功能，但是想要完成搜索工作的创建是非常困难的。我们希望搜索解决方案要运行速度快，我们希望能有一个零配置和一个完全免费的搜索模式，我们希望能够简单地使用JSON通过HTTP来索引数据，我们希望我们的搜索服务器始终可用，我们希望能够从一台开始并扩展到数百台，我们要实时搜索，我们要简单的多租户，我们希望建立一个云的解决方案。因此我们利用Elasticsearch来解决所有这些问题及可能出现的更多其它问题。

官网：https://www.elastic.co/cn/products/elasticsearch

2.2、安装

2.2.1、版本说明

Elasticsearch的发展是非常快速的，所以在ES5.0之前，ELK的各个版本都不统一，出现了版本号混乱的状态，所以从5.0开始，所有Elastic Stack中的项目全部统一版本号。目前最新版本是6.5.4，我们将基于这一版本进行学习。

2.2.2、下载

地址：https://www.elastic.co/cn/downloads/elasticsearch

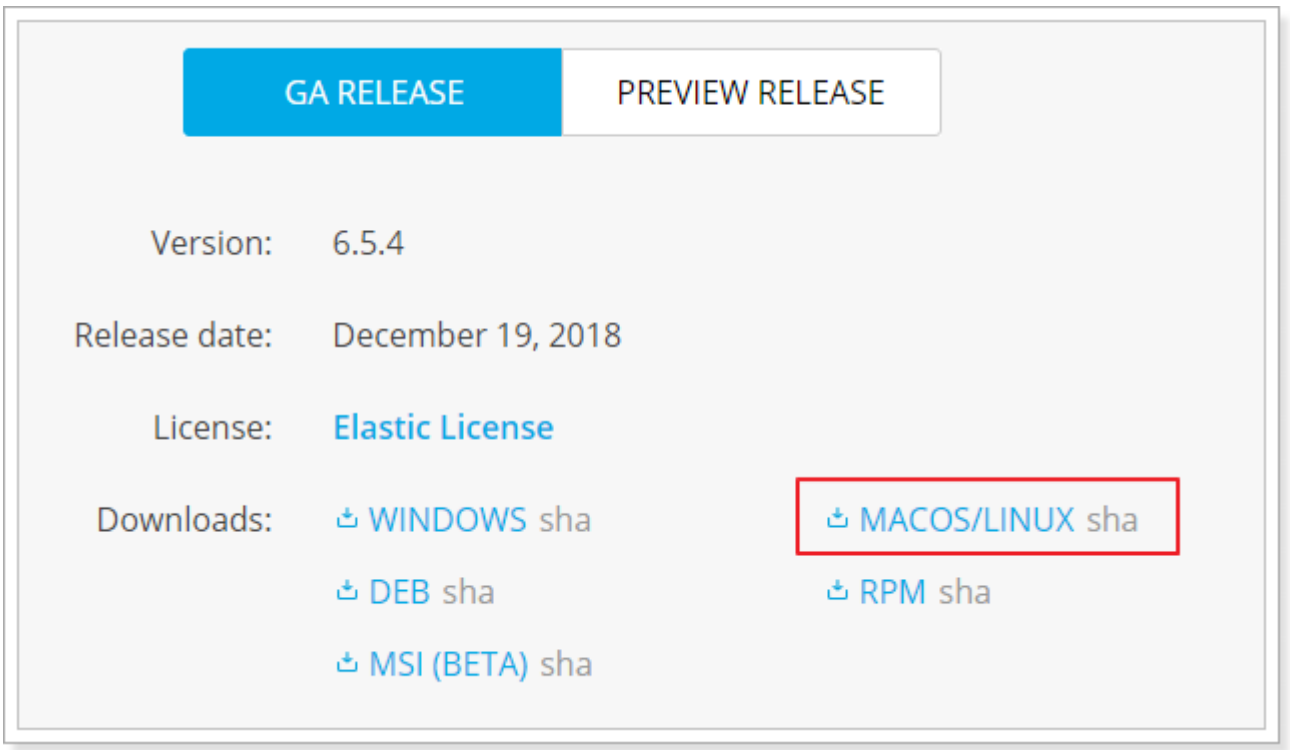

或者，使用资料中提供的已下载好的安装包。

2.2.3、单机版安装

```
#创建elsearch用户，Elasticsearch不支持root用户运行
useradd elsearch

#解压安装包
tar -xvf elasticsearch-6.5.4.tar.gz -C /haoke/es/
```

```
#修改配置文件
vim conf/elasticsearch.yml
network.host: 172.16.55.185  #绑定的地址

#说明：在Elasticsearch中如果，network.host不是localhost或者127.0.0.1的话，就会认为是生产环境，会对环境的要求比较高，我们的测试环境不一定能够满足，一般情况下需要修改2处配置，如下：
#1：修改jvm启动参数
vim conf/jvm.options
-Xms128m #根据自己机器情况修改
-Xmx128m
#2：单个进程中的最大线程数
vim /etc/sysctl.conf
vm.max_map_count=655360

#启动ES服务
su - elsearch
cd bin
./elasticsearch 或 ./elasticsearch -d #后台系统

#通过访问http://172.16.55.185:9200进行测试，看到如下信息，就说明ES启动成功了
{
    "name": "dSQV6I8",
    "cluster_name": "elasticsearch",
    "cluster_uuid": "v5GPTWAtT5emxFdjigFg-w",
    "version": {
        "number": "6.5.4",
        "build_flavor": "default",
        "build_type": "tar",
        "build_hash": "d2ef93d",
        "build_date": "2018-12-17T21:17:40.758843Z",
        "build_snapshot": false,
        "lucene_version": "7.5.0",
        "minimum_wire_compatibility_version": "5.6.0",
        "minimum_index_compatibility_version": "5.0.0"
    },
    "tagline": "You Know, for Search"
}

#停止服务
root@itcast:~# jps
68709 Jps
68072 Elasticsearch

kill 68072  #通过kill结束进程
```

2.2.4、使用docker安装

```
#拉取镜像
docker pull elasticsearch:6.5.4

#创建容器
docker create --name elasticsearch --net host -e "discovery.type=single-node" -e "network.host=172.16.55.185" elasticsearch:6.5.4

#启动
docker start elasticsearch

#查看日志
docker logs elasticsearch
```

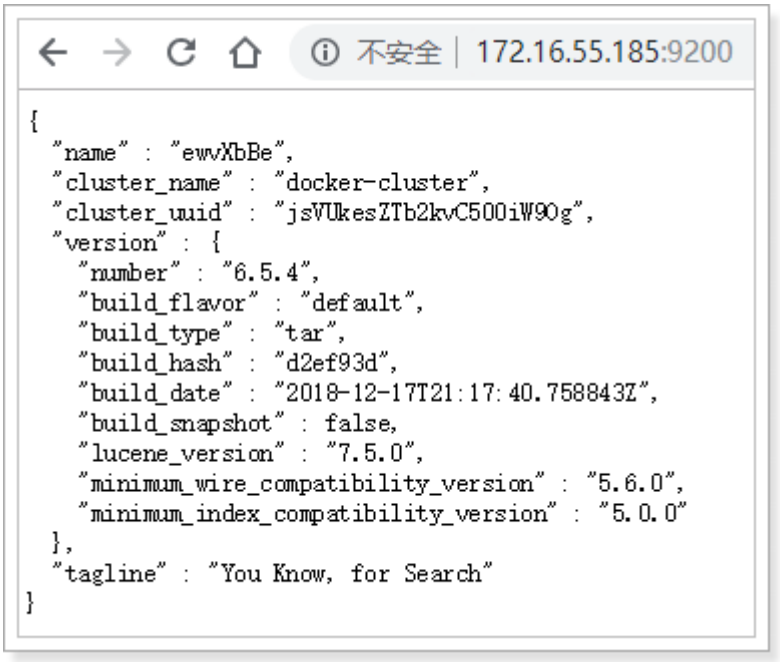

可以看到，效果一样。

> 需要说明的是：此docker安装是开发环境模式，并没有配置目录挂载等内容，生成集群环境的搭建后面讲解。

2.2.5、elasticsearch-head

由于ES官方并没有为ES提供界面管理工具，仅仅是提供了后台的服务。elasticsearch-head是一个为ES开发的一个页面客户端工具，其源码托管于GitHub，地址为：https://github.com/mobz/elasticsearch-head

head提供了4种安装方式：

- 源码安装，通过npm run start启动（不推荐）
- 通过docker安装（推荐）
- 通过chrome插件安装（推荐）
- 通过ES的plugin方式安装（不推荐）

> 通过docker安装

```
#拉取镜像
docker pull mobz/elasticsearch-head:5

#创建容器
docker create --name elasticsearch-head -p 9100:9100 mobz/elasticsearch-head:5

#启动容器
docker start elasticsearch-head
```

通过浏览器进行访问：

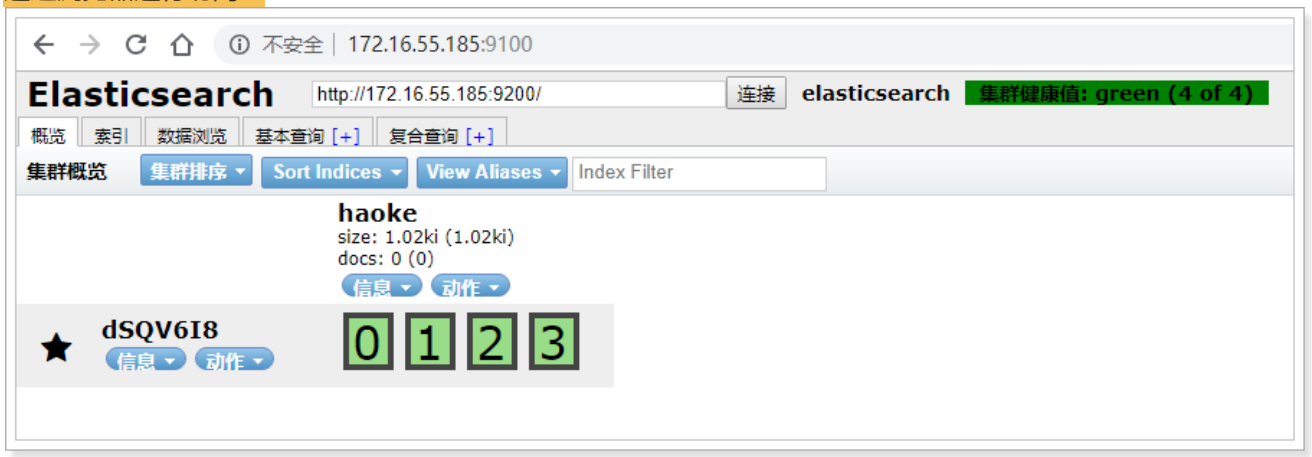

> 注意：
>
> 由于前后端分离开发，所以会存在跨域问题，需要在服务端做CORS的配置，如下：
>
> vim elasticsearch.yml
>
> http.cors.enabled: true http.cors.allow-origin: "*"
>
> *通过chrome插件的方式安装不存在该问题。*

> chrome插件的方式安装

打开chrome的应用商店，即可安装https://chrome.google.com/webstore/detail/elasticsearch-head/ffmkiejjmecolpfloofpjologoblkegm

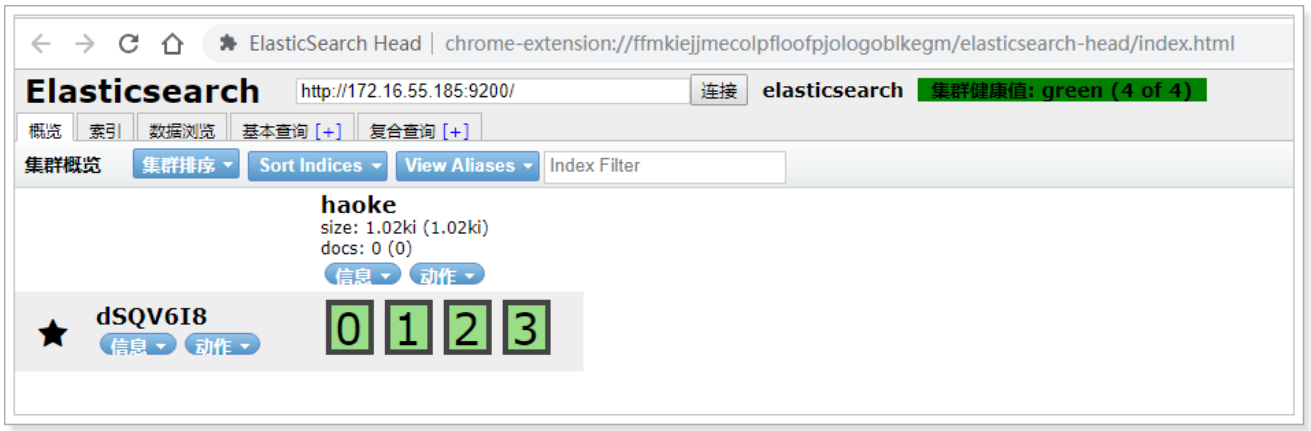

> 建议：推荐使用chrome插件的方式安装，如果网络环境不允许，就采用docker方式安装。

2.3、基本概念

> 索引

- 索引（index）是Elasticsearch对逻辑数据的逻辑存储，所以它可以分为更小的部分。
- 可以把索引看成关系型数据库的表，索引的结构是为快速有效的全文索引准备的，特别是它不存储原始值。
- 可以把Elasticsearch的索引看成MongoDB里的一个集合。
- Elasticsearch可以把索引存放在一台机器或者分散在多台服务器上，每个索引有一或多个分片（shard），每个分片可以有多个副本（replica）。

> 文档

- 存储在Elasticsearch中的主要实体叫文档（document）。用关系型数据库来类比的话，一个文档相当于数据库表中的一行记录。
- Elasticsearch和MongoDB中的文档类似，都可以有不同的结构，但Elasticsearch的文档中，相同字段必须有相同类型。
- 文档由多个字段组成，每个字段可能多次出现在一个文档里，这样的字段叫多值字段（multivalued）。
- 每个字段的类型，可以是文本、数值、日期等。字段类型也可以是复杂类型，一个字段包含其他子文档或者数组。

> 映射

- 所有文档写进索引之前都会先进行分析，如何将输入的文本分割为词条、哪些词条又会被过滤，这种行为叫做映射（mapping）。一般由用户自己定义规则。

> 文档类型

- 在Elasticsearch中，一个索引对象可以存储很多不同用途的对象。例如，一个博客应用程序可以保存文章和评论。
- 每个文档可以有不同的结构。
- 不同的文档类型不能为相同的属性设置不同的类型。例如，在同一索引中的所有文档类型中，一个叫title的字段必须具有相同的类型。

2.4、RESTful API

在Elasticsearch中，提供了功能丰富的RESTful API的操作，包括基本的CRUD、创建索引、删除索引等操作。

2.4.1、创建非结构化索引

在Lucene中，创建索引是需要定义字段名称以及字段的类型的，在Elasticsearch中提供了非结构化的索引，就是不需要创建索引结构，即可写入数据到索引中，实际上在Elasticsearch底层会进行结构化操作，此操作对用户是透明的。

创建空索引：

```
PUT http://172.16.55.185:9200/haoke

{
   "settings": {
      "index": {
         "number_of_shards": "2", #分片数
         "number_of_replicas": "0" #副本数
      }
   }
}

```

```
#删除索引
DELETE http://172.16.55.185:9200/haoke
{
   "acknowledged": true
}
```

2.4.2、插入数据

> URL规则：
>
> POST http://172.16.55.185:9200/{索引}/{类型}/{id}

```
POST http://172.16.55.185:9200/haoke/user/1001
#数据
{
  "id":1001,
  "name":"张三",
  "age":20,
  "sex":"男"
}

#响应
{
    "_index": "haoke",
    "_type": "user",
    "_id": "1",
    "_version": 1,
    "result": "created",
    "_shards": {
        "total": 1,
        "successful": 1,
        "failed": 0
    },
    "_seq_no": 0,
    "_primary_term": 1
}
```

> 说明：非结构化的索引，不需要事先创建，直接插入数据默认创建索引。

不指定id插入数据：

```
POST http://172.16.55.185:9200/haoke/user/
{
  "id":1002,
  "name":"张三",
  "age":20,
  "sex":"男"
}
```

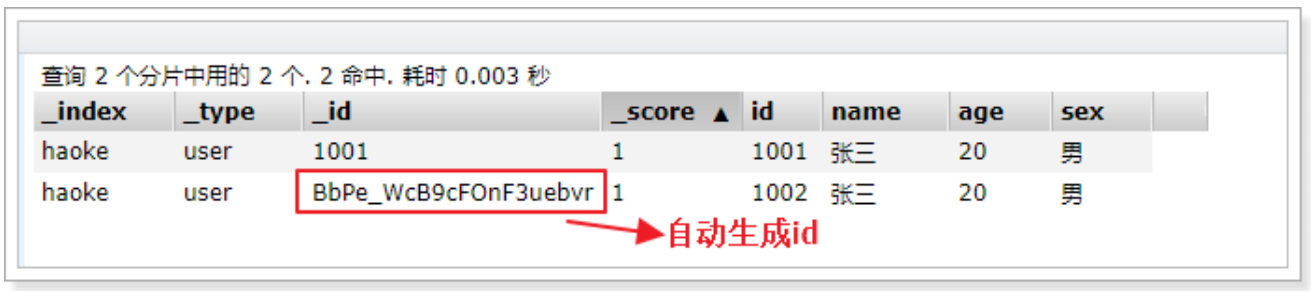

2.4.3、更新数据

在Elasticsearch中，文档数据是不为修改的，但是可以通过覆盖的方式进行更新。

```
PUT http://172.16.55.185:9200/haoke/user/1001

{
  "id":1001,
  "name":"张三",
  "age":21,
  "sex":"女"
}

```

更新结果如下：

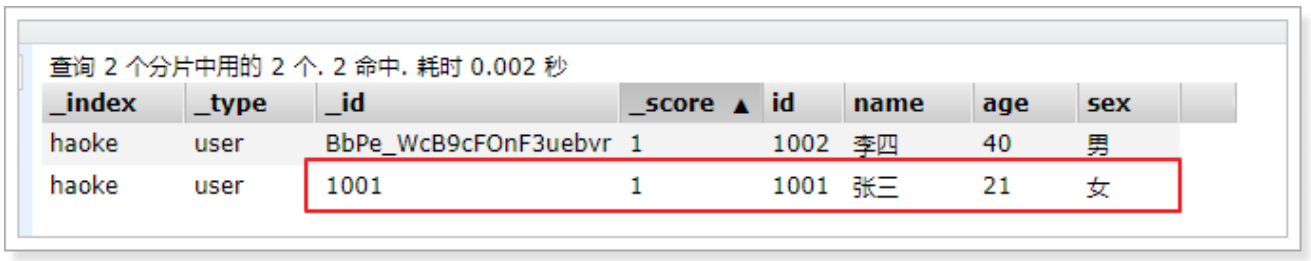

可以看到数据已经被覆盖了。

问题来了，可以局部更新吗？ -- 可以的。

前面不是说，文档数据不能更新吗？ 其实是这样的：

在内部，依然会查询到这个文档数据，然后进行覆盖操作，步骤如下：

1. 从旧文档中检索JSON
2. 修改它
3. 删除旧文档
4. 索引新文档

示例：

```
#注意：这里多了_update标识
POST http://172.16.55.185:9200/haoke/user/1001/_update

{
 "doc":{
   "age":23
  }
}

```

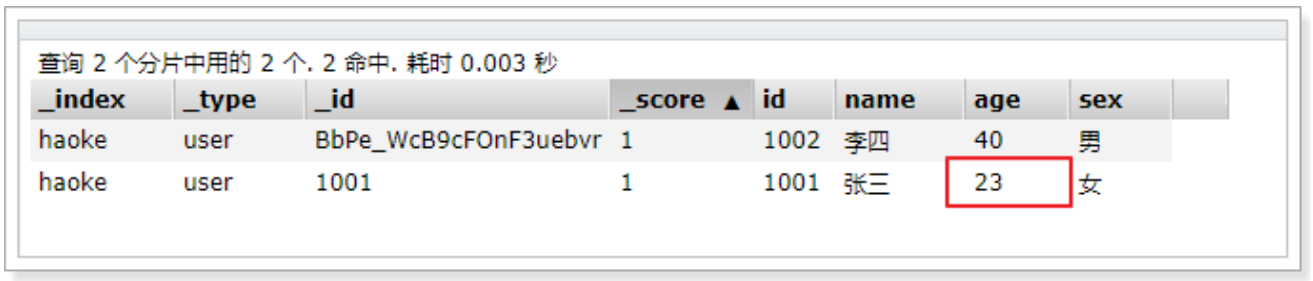

可以看到数据已经被局部更新了。

2.4.4、删除数据

在Elasticsearch中，删除文档数据，只需要发起DELETE请求即可。

```
DELETE http://172.16.55.185:9200/haoke/user/1001
```

需要注意的是，result表示已经删除，version也更加了。

如果删除一条不存在的数据，会响应404：

> 说明：
>
> 删除一个文档也不会立即从磁盘上移除，它只是被标记成已删除。Elasticsearch将会在你之后添加更多索引的时候才会在后台进行删除内容的清理。

2.4.5、搜索数据

> 根据id搜索数据

```
GET http://172.16.55.185:9200/haoke/user/BbPe_WcB9cFOnF3uebvr

#返回的数据如下
{
    "_index": "haoke",
    "_type": "user",
    "_id": "BbPe_WcB9cFOnF3uebvr",
    "_version": 8,
    "found": true,
    "_source": {  #原始数据在这里
        "id": 1002,
```

```
        "name": "李四",
        "age": 40,
        "sex": "男"
    }
}
```

搜索全部数据

```
GET http://172.16.55.185:9200/haoke/user/_search
```

响应：（默认返回10条数据）

```
{
    "took": 26,
    "timed_out": false,
    "_shards": {
        "total": 2,
        "successful": 2,
        "skipped": 0,
        "failed": 0
    },
    "hits": {
        "total": 4,
        "max_score": 1,
        "hits": [
            {
                "_index": "haoke",
                "_type": "user",
                "_id": "BbPe_WcB9cFOnF3uebvr",
                "_score": 1,
                "_source": {
                    "id": 1002,
                    "name": "李四",
                    "age": 40,
                    "sex": "男"
                }
            },
            {
                "_index": "haoke",
                "_type": "user",
                "_id": "1001",
                "_score": 1,
                "_source": {
                    "id": 1001,
                    "name": "张三",
                    "age": 20,
                    "sex": "男"
                }
            },
            {
                "_index": "haoke",
                "_type": "user",
```

```
                "_id": "1003",
                "_score": 1,
                "_source": {
                    "id": 1003,
                    "name": "王五",
                    "age": 30,
                    "sex": "男"
                }
            },
            {
                "_index": "haoke",
                "_type": "user",
                "_id": "1004",
                "_score": 1,
                "_source": {
                    "id": 1004,
                    "name": "赵六",
                    "age": 30,
                    "sex": "男"
                }
            }
        ]
    }
}
```

关键字搜素数据

```
#查询年龄等于20的用户
GET http://172.16.55.185:9200/haoke/user/_search?q=age:20

```

结果：

2.4.6、DSL搜索

Elasticsearch提供丰富且灵活的查询语言叫做**DSL查询(Query DSL)**,它允许你构建更加复杂、强大的查询。

DSL(Domain Specific Language特定领域语言)以JSON请求体的形式出现。

```
POST http://172.16.55.185:9200/haoke/user/_search

#请求体
{
    "query" : {
        "match" : {   #match只是查询的一种
            "age" : 20
        }
    }
}
```

响应数据：

Raw JSON Response

Copy to clipboard Save as file


```
{
    took: 5
    timed_out: false
  -_shards: {
        total: 2
        successful: 2
        skipped: 0
        failed: 0
    }
  -hits: {
        total: 1
        max_score: 1
      -hits: [1]
         -0:    {
                _index: "haoke"
                _type: "user"
                _id: "1001"
                _score: 1
              -_source: {
                    id: 1001
                    name: "张三"
                    age: 20
                    sex: "男"
                }
            }
    }
}
```


> 实现：查询年龄大于30岁的男性用户。

现有数据：

查询 2 个分片中用的 2 个. 4 命中. 耗时 0.004 秒

_index	_type	_id	_score ▲	id	name	age	sex
haoke	user	BbPe_WcB9cFOnF3uebvr	1	1002	李四	40	男
haoke	user	1001	1	1001	张三	20	男
haoke	user	1003	1	1003	王五	30	男
haoke	user	1004	1	1004	赵六	30	女

```
POST http://172.16.55.185:9200/haoke/user/_search
#请求数据
{
    "query": {
        "bool": {
            "filter": {
```

```
                "range": {
                    "age": {
                        "gt": 30
                    }
                }
            },
            "must": {
                "match": {
                    "sex": "男"
                }
            }
        }
    }
}
```

查询结果：

全文搜索

```
POST http://172.16.55.185:9200/haoke/user/_search
#请求数据
{
    "query": {
        "match": {
            "name": "张三 李四"
        }
    }
}
```

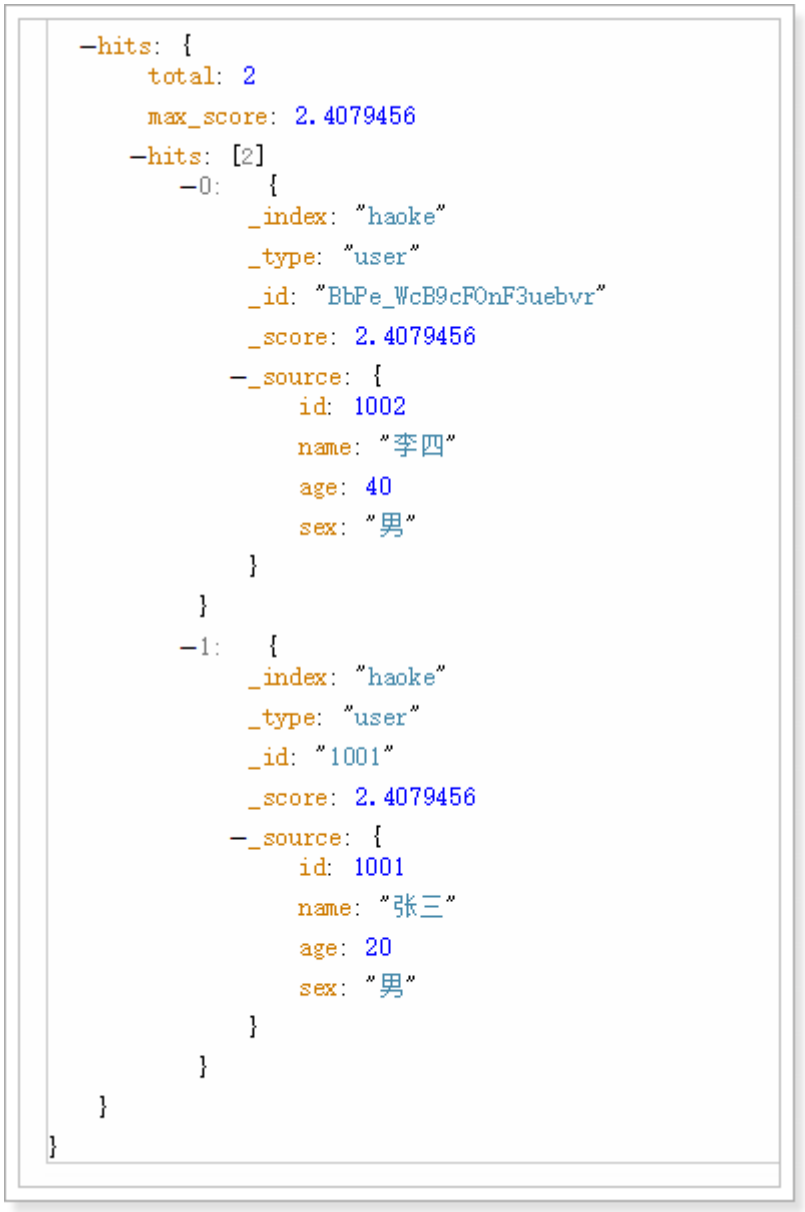

2.4.7、高亮显示

```
POST http://172.16.55.185:9200/haoke/user/_search

{
    "query": {
        "match": {
            "name": "张三 李四"
```

```
        }
    },
    "highlight": {
        "fields": {
            "name": {}
        }
    }
}
```

2.4.8、聚合

在Elasticsearch中，支持聚合操作，类似SQL中的group by操作。

```
POST http://172.16.55.185:9200/haoke/user/_search

{
    "aggs": {
        "all_interests": {
            "terms": {
                "field": "age"
            }
        }
    }
}
```

结果：

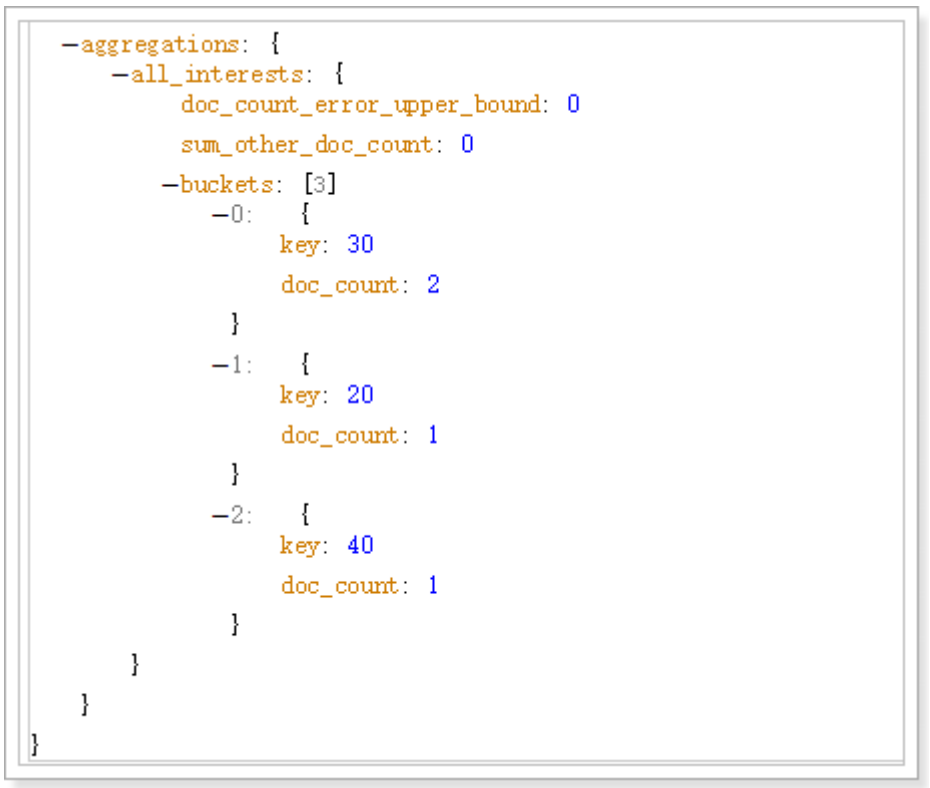

从结果可以看出，年龄30的有2条数据，20的有一条，40的一条。

3、核心详解

3.1、文档

在Elasticsearch中，文档以JSON格式进行存储，可以是复杂的结构，如：

```
{
    "_index": "haoke",
    "_type": "user",
    "_id": "1005",
    "_version": 1,
    "_score": 1,
```

```
    "_source": {
        "id": 1005,
        "name": "孙七",
        "age": 37,
        "sex": "女",
        "card": {
            "card_number": "123456789"
        }
    }
}
```

其中，card是一个复杂对象，嵌套的Card对象。

> 元数据（metadata）

一个文档不只有数据。它还包含了元数据(metadata)——关于文档的信息。三个必须的元数据节点是：

节点	说明
`_index`	文档存储的地方
`_type`	文档代表的对象的类
`_id`	文档的唯一标识

> **_index**

索引(index)类似于关系型数据库里的"数据库"——它是我们存储和索引关联数据的地方。

> **提示：**
>
> 事实上，我们的数据被存储和索引在**分片(shards)**中，索引只是一个把一个或多个分片分组在一起的逻辑空间。然而，这只是一些内部细节——我们的程序完全不用关心分片。对于我们的程序而言，文档存储在**索引(index)**中。剩下的细节由Elasticsearch关心既可。

> **_type**

在应用中，我们使用对象表示一些"事物"，例如一个用户、一篇博客、一个评论，或者一封邮件。每个对象都属于一个**类(class)**，这个类定义了属性或与对象关联的数据。`user`类的对象可能包含姓名、性别、年龄和Email地址。

在关系型数据库中，我们经常将相同类的对象存储在一个表里，因为它们有着相同的结构。同理，在Elasticsearch中，我们使用相同**类型(type)**的文档表示相同的"事物"，因为他们的数据结构也是相同的。

每个**类型(type)**都有自己的**映射(mapping)**或者结构定义，就像传统数据库表中的列一样。所有类型下的文档被存储在同一个索引下，但是类型的**映射(mapping)**会告诉Elasticsearch不同的文档如何被索引。

`_type`的名字可以是大写或小写，不能包含下划线或逗号。我们将使用`blog`做为类型名。

> **_id**

id仅仅是一个字符串，它与`_index`和`_type`组合时，就可以在Elasticsearch中唯一标识一个文档。当创建一个文档，你可以自定义`_id`，也可以让Elasticsearch帮你自动生成（32位长度）。

3.2、查询响应

3.2.1、pretty

可以在查询url后面添加pretty参数，使得返回的json更易查看。

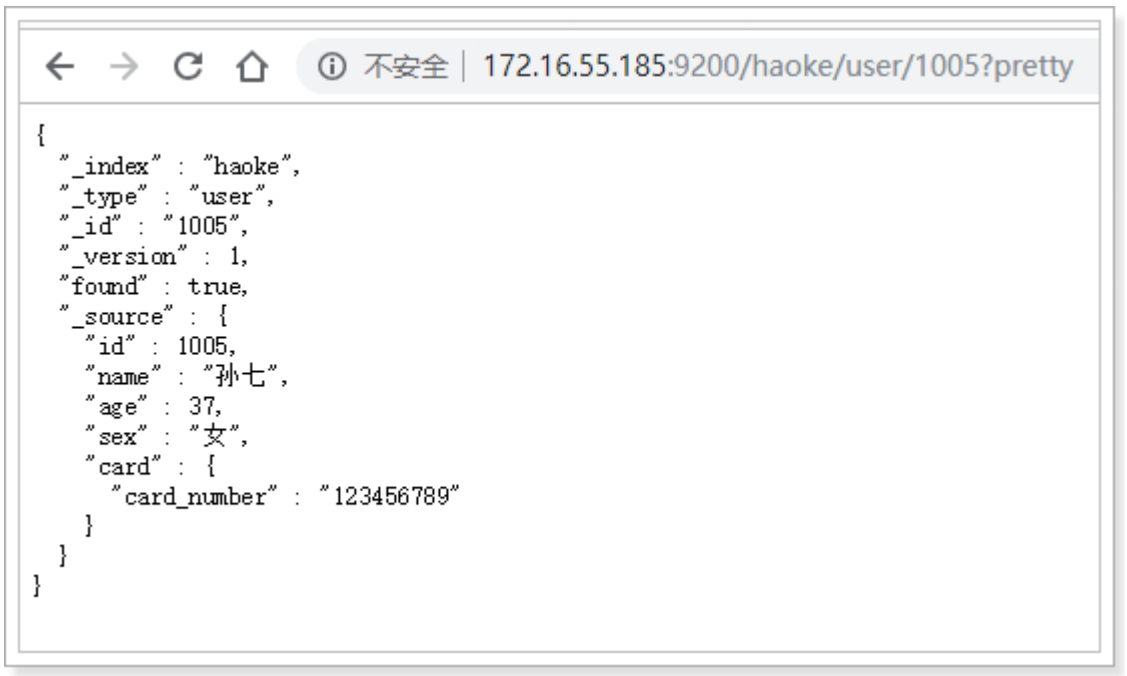

3.2.2、指定响应字段

在响应的数据中，如果我们不需要全部的字段，可以指定某些需要的字段进行返回。

```
GET http://172.16.55.185:9200/haoke/user/1005?_source=id,name
#响应
{
    "_index": "haoke",
    "_type": "user",
    "_id": "1005",
    "_version": 1,
    "found": true,
    "_source": {
        "name": "孙七",
        "id": 1005
    }
}
```

如不需要返回元数据，仅仅返回原始数据，可以这样：

```
GET http://172.16.55.185:9200/haoke/user/1005/_source
```

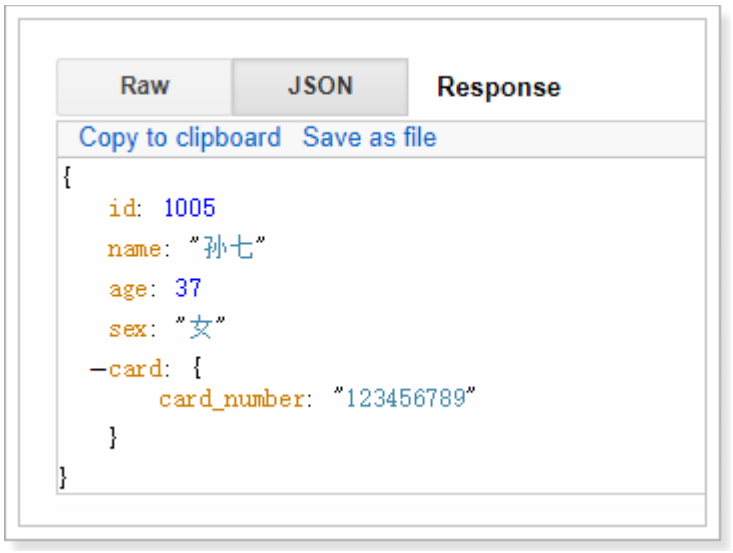

还可以这样：

```
GET http://172.16.55.185:9200/haoke/user/1005/_source?_source=id,name
```

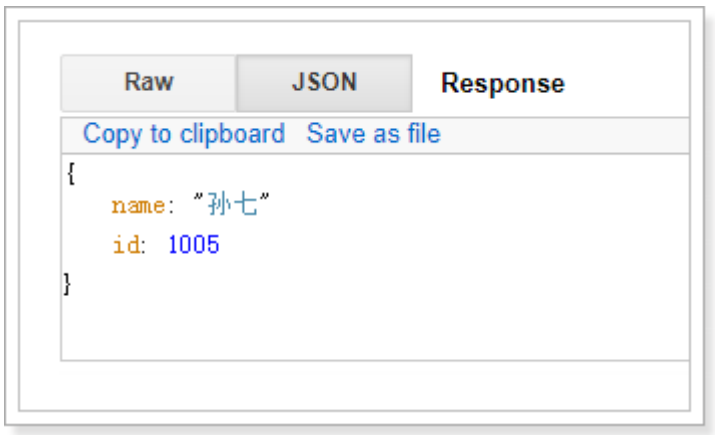

3.3、判断文档是否存在

如果我们只需要判断文档是否存在，而不是查询文档内容，那么可以这样：

```
HEAD http://172.16.55.185:9200/haoke/user/1005
```

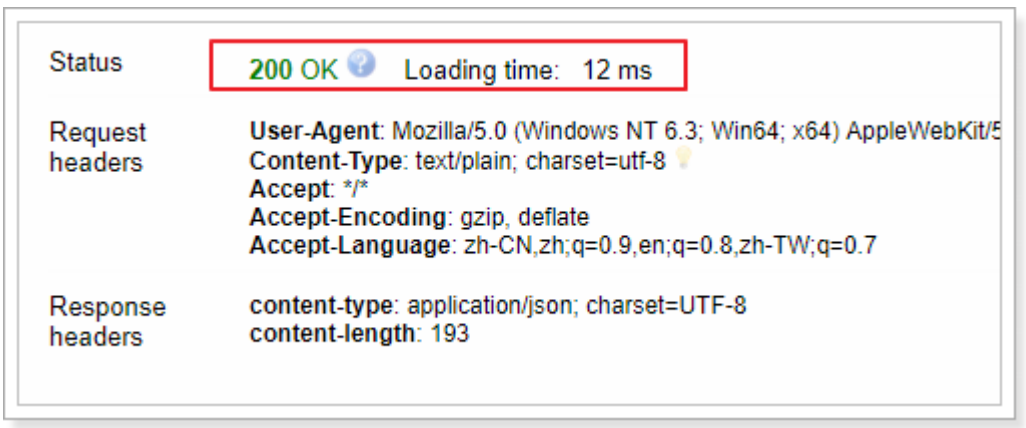

```
HEAD http://172.16.55.185:9200/haoke/user/1006
```

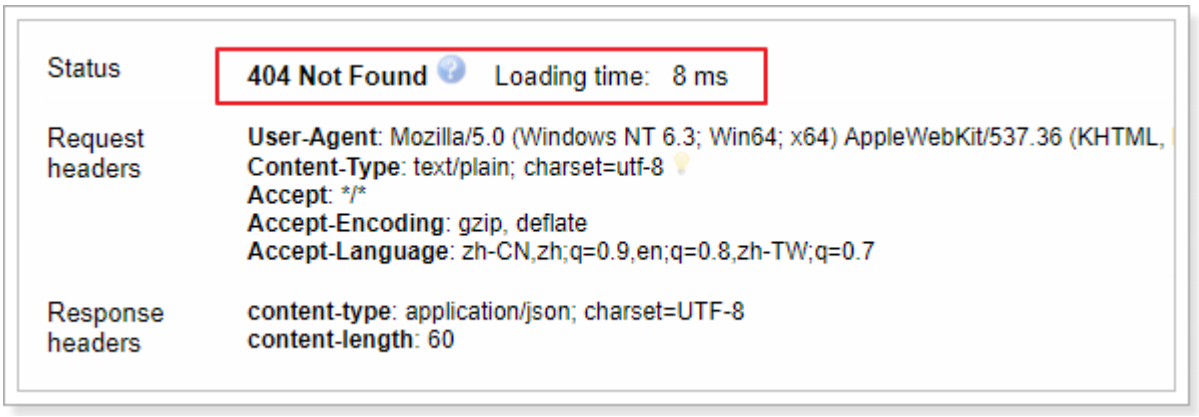

> 当然，这只表示你在查询的那一刻文档不存在，但并不表示几毫秒后依旧不存在。另一个进程在这期间可能创建新文档。

3.4、批量操作

有些情况下可以通过批量操作以减少网络请求。如：批量查询、批量插入数据。

3.4.1、批量查询

```
POST http://172.16.55.185:9200/haoke/user/_mget

{
   "ids" : [ "1001", "1003" ]
}
```

结果：

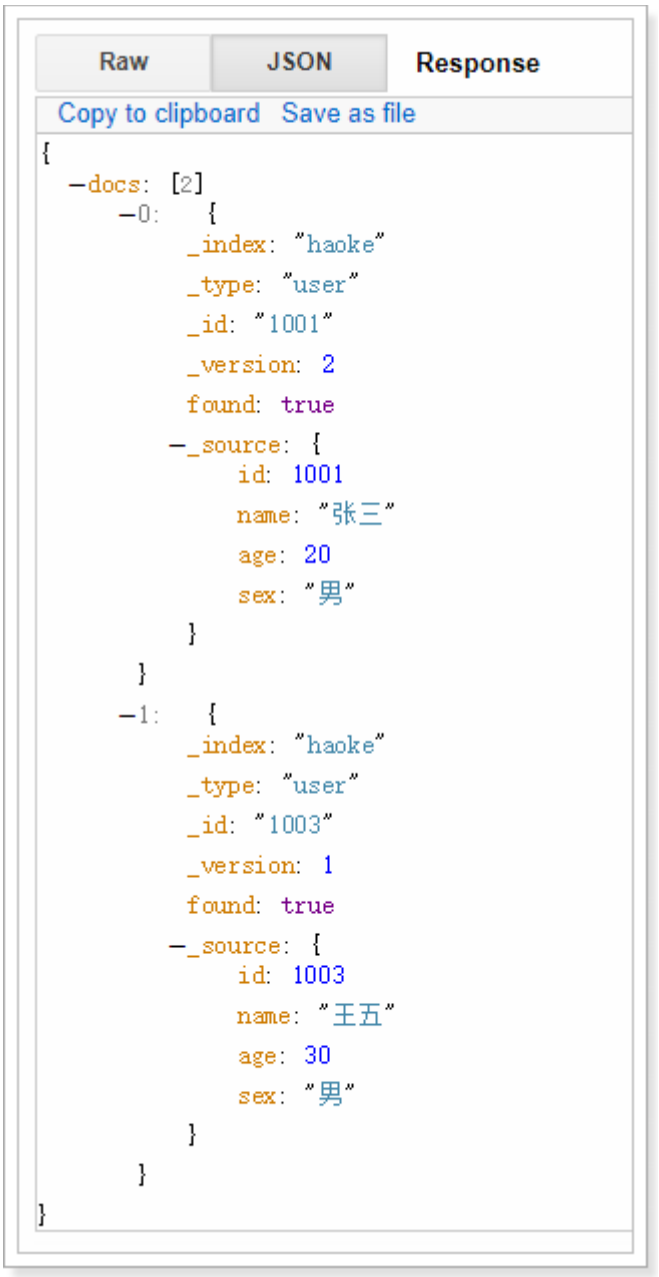

如果，某一条数据不存在，不影响整体响应，需要通过found的值进行判断是否查询到数据。

```
POST http://172.16.55.185:9200/haoke/user/_mget

{
   "ids" : [ "1001", "1006" ]
}
```

结果：

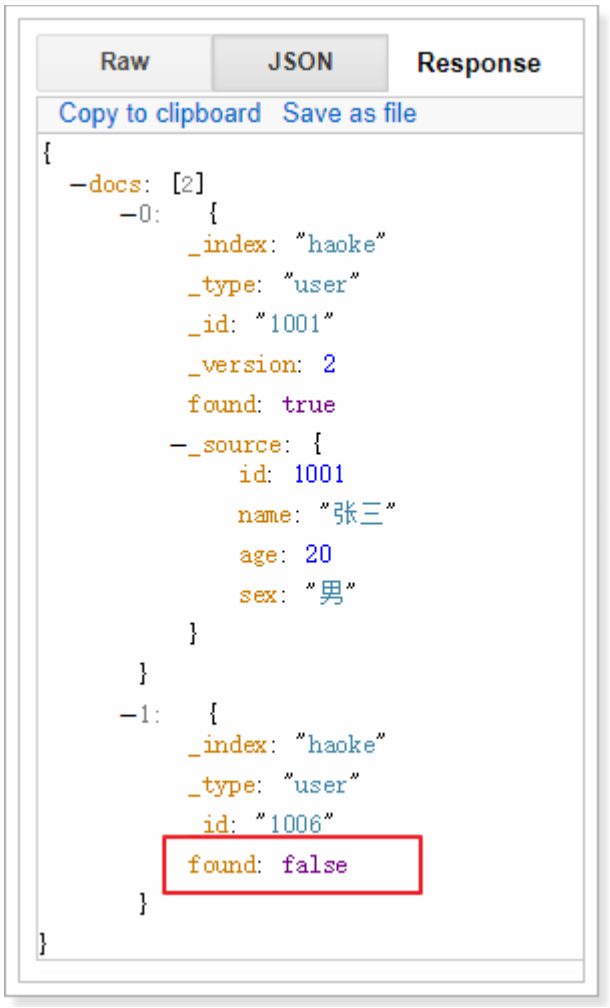

3.4.2、_bulk操作

在Elasticsearch中，支持批量的插入、修改、删除操作，都是通过_bulk的api完成的。

请求格式如下：（请求格式不同寻常）

```
{ action: { metadata }}\n
{ request body        }\n
{ action: { metadata }}\n
{ request body        }\n
...
```

> 批量插入数据：

```
{"create":{"_index":"haoke","_type":"user","_id":2001}}
{"id":2001,"name":"name1","age": 20,"sex": "男"}
{"create":{"_index":"haoke","_type":"user","_id":2002}}
{"id":2002,"name":"name2","age": 20,"sex": "男"}
{"create":{"_index":"haoke","_type":"user","_id":2003}}
{"id":2003,"name":"name3","age": 20,"sex": "男"}

```

> 注意最后一行的回车。

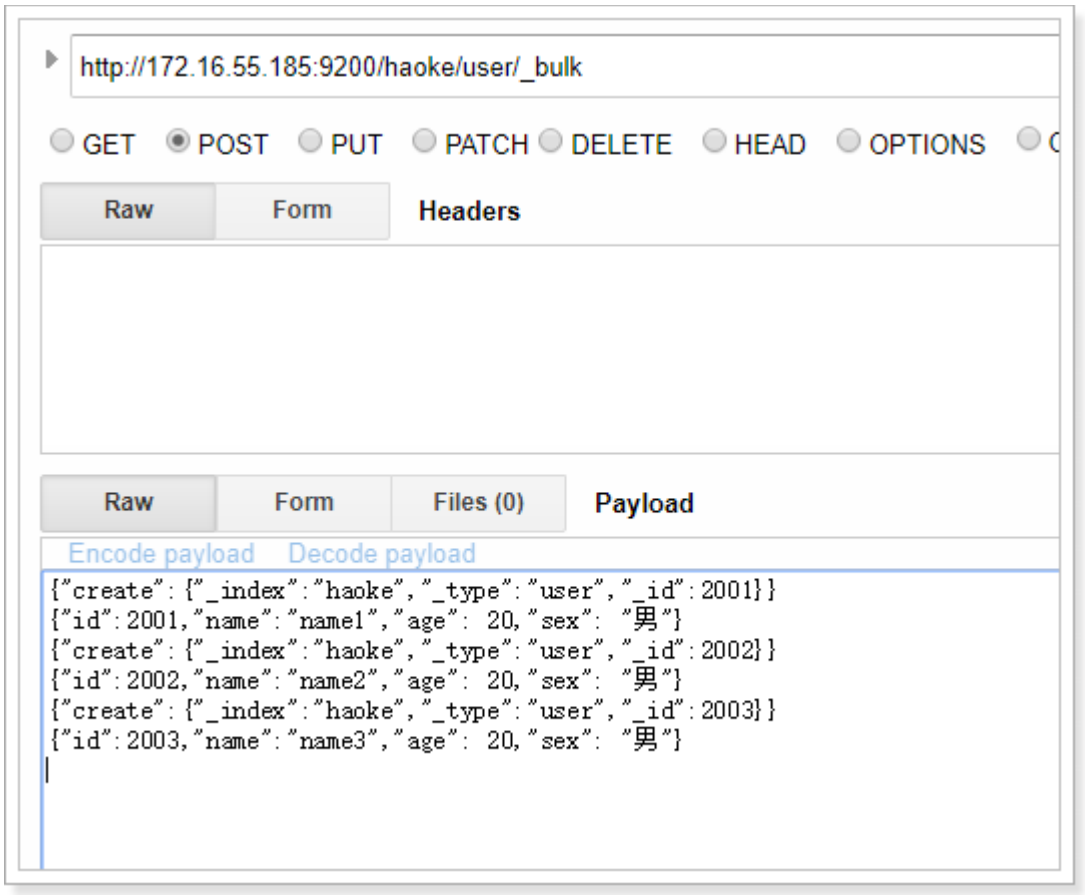

响应结果：


```
{
    "took": 17,
    "errors": false,
    "items": [
        {
            "create": {
                "_index": "haoke",
                "_type": "user",
                "_id": "2001",
                "_version": 1,
                "result": "created",
                "_shards": {
                    "total": 1,
                    "successful": 1,
                    "failed": 0
                },
                "_seq_no": 24,
                "_primary_term": 1,
                "status": 201
            }
        },
        {
            "create": {
                "_index": "haoke",
                "_type": "user",
                "_id": "2002",
```

```
                "_version": 1,
                "result": "created",
                "_shards": {
                    "total": 1,
                    "successful": 1,
                    "failed": 0
                },
                "_seq_no": 0,
                "_primary_term": 1,
                "status": 201
            }
        },
        {
            "create": {
                "_index": "haoke",
                "_type": "user",
                "_id": "2003",
                "_version": 1,
                "result": "created",
                "_shards": {
                    "total": 1,
                    "successful": 1,
                    "failed": 0
                },
                "_seq_no": 1,
                "_primary_term": 1,
                "status": 201
            }
        }
    ]
}
```

批量删除：

```
{"delete":{"_index":"haoke","_type":"user","_id":2001}}
{"delete":{"_index":"haoke","_type":"user","_id":2002}}
{"delete":{"_index":"haoke","_type":"user","_id":2003}}

```

由于delete没有请求体，所以，action的下一行直接就是下一个action。

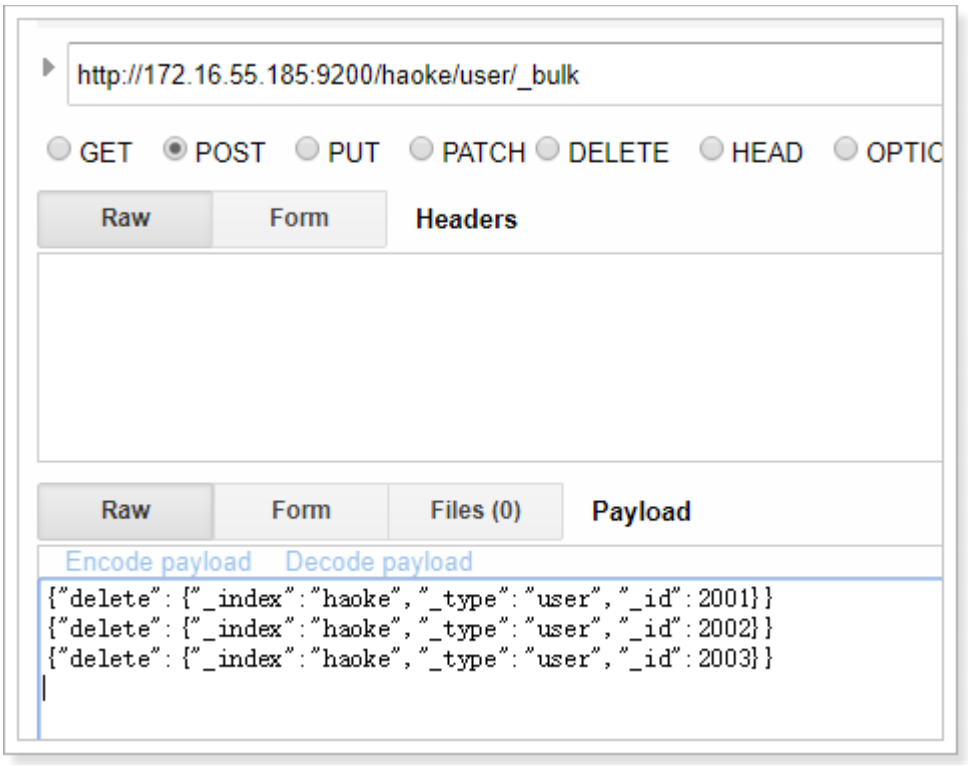


```
{
    "took": 3,
    "errors": false,
    "items": [
        {
            "delete": {
                "_index": "haoke",
                "_type": "user",
                "_id": "2001",
                "_version": 2,
                "result": "deleted",
                "_shards": {
                    "total": 1,
                    "successful": 1,
                    "failed": 0
                },
                "_seq_no": 25,
                "_primary_term": 1,
                "status": 200
            }
        },
        {
            "delete": {
                "_index": "haoke",
                "_type": "user",
                "_id": "2002",
                "_version": 2,
                "result": "deleted",
                "_shards": {
                    "total": 1,
                    "successful": 1,
```

```
                    "failed": 0
                },
                "_seq_no": 2,
                "_primary_term": 1,
                "status": 200
            }
        },
        {
            "delete": {
                "_index": "haoke",
                "_type": "user",
                "_id": "2003",
                "_version": 2,
                "result": "deleted",
                "_shards": {
                    "total": 1,
                    "successful": 1,
                    "failed": 0
                },
                "_seq_no": 3,
                "_primary_term": 1,
                "status": 200
            }
        }
    ]
}
```

其他操作就类似了。

一次请求多少性能最高？

- 整个批量请求需要被加载到接受我们请求节点的内存里，所以请求越大，给其它请求可用的内存就越小。有一个最佳的bulk请求大小。超过这个大小，性能不再提升而且可能降低。
- 最佳大小，当然并不是一个固定的数字。它完全取决于你的硬件、你文档的大小和复杂度以及索引和搜索的负载。
- 幸运的是，这个最佳点(sweetspot)还是容易找到的：试着批量索引标准的文档，随着大小的增长，当性能开始降低，说明你每个批次的大小太大了。开始的数量可以在1000~5000个文档之间，如果你的文档非常大，可以使用较小的批次。
- 通常着眼于你请求批次的物理大小是非常有用的。一千个1kB的文档和一千个1MB的文档大不相同。一个好的批次最好保持在5-15MB大小间。

3.5、分页

和SQL使用`LIMIT`关键字返回只有一页的结果一样，Elasticsearch接受`from`和`size`参数：

```
size: 结果数，默认10
from: 跳过开始的结果数，默认0
```

如果你想每页显示5个结果，页码从1到3，那请求如下：

```
GET /_search?size=5
GET /_search?size=5&from=5
GET /_search?size=5&from=10
```

> 应该当心分页太深或者一次请求太多的结果。结果在返回前会被排序。但是记住一个搜索请求常常涉及多个分片。每个分片生成自己排好序的结果，它们接着需要集中起来排序以确保整体排序正确。

```
GET http://172.16.55.185:9200/haoke/user/_search?size=1&from=2
```

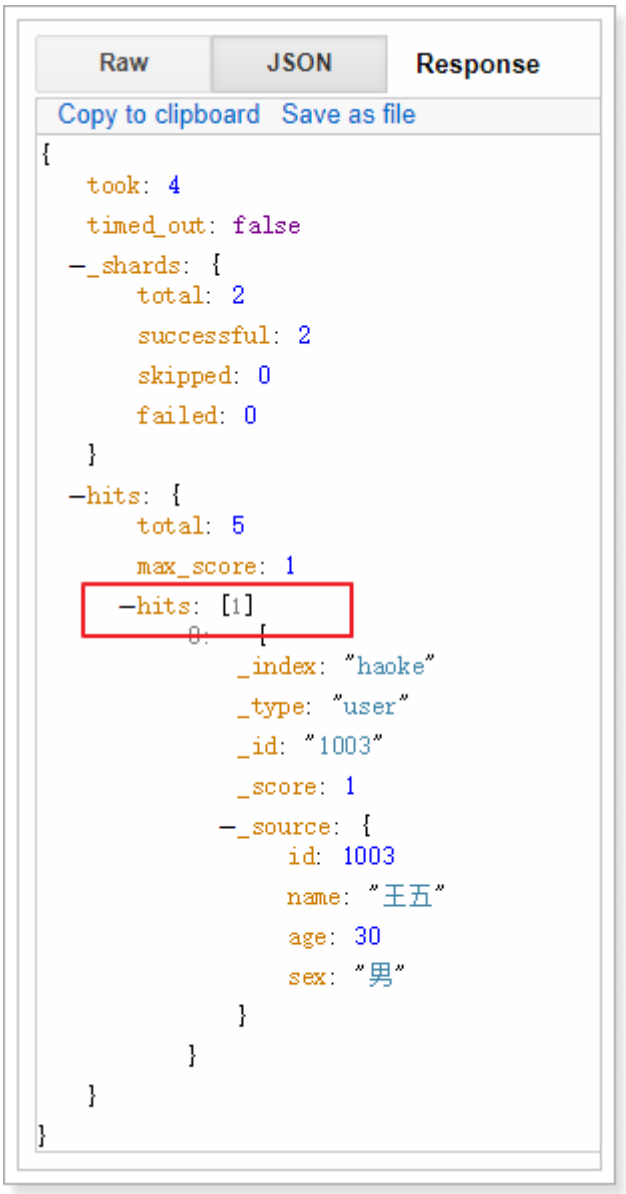

> **在集群系统中深度分页**
>
> 为了理解为什么深度分页是有问题的，让我们假设在一个有5个主分片的索引中搜索。当我们请求结果的第一页（结果1到10）时，每个分片产生自己最顶端10个结果然后返回它们给**请求节点(requesting node)**，它再排序这所有的50个结果以选出顶端的10个结果。
>
> 现在假设我们请求第1000页——结果10001到10010。工作方式都相同，不同的是每个分片都必须产生顶端的10010个结果。然后请求节点排序这50050个结果并丢弃50040个！

> 你可以看到在分布式系统中，排序结果的花费随着分页的深入而成倍增长。这也是为什么网络搜索引擎中任何语句不能返回多于1000个结果的原因。

3.6、映射

前面我们创建的索引以及插入数据，都是由Elasticsearch进行自动判断类型，有些时候我们是需要进行明确字段类型的，否则，自动判断的类型和实际需求是不相符的。

自动判断的规则如下：

JSON type	Field type
Boolean: `true` or `false`	`"boolean"`
Whole number: `123`	`"long"`
Floating point: `123.45`	`"double"`
String, valid date: `"2014-09-15"`	`"date"`
String: `"foo bar"`	`"string"`

Elasticsearch中支持的类型如下：

类型	表示的数据类型
String	`string`，`text`，`keyword`
Whole number	`byte`，`short`，`integer`，`long`
Floating point	`float`，`double`
Boolean	`boolean`
Date	`date`

> - string类型在ElasticSearch 旧版本中使用较多，从ElasticSearch 5.x开始不再支持string，由text和keyword类型替代。
> - text 类型，当一个字段是要被全文搜索的，比如Email内容、产品描述，应该使用text类型。设置text类型以后，字段内容会被分析，在生成倒排索引以前，字符串会被分析器分成一个一个词项。text类型的字段不用于排序，很少用于聚合。
> - keyword类型适用于索引结构化的字段，比如email地址、主机名、状态码和标签。如果字段需要进行过滤(比如查找已发布博客中status属性为published的文章)、排序、聚合。keyword类型的字段只能通过精确值搜索到。

创建明确类型的索引：

```
PUT http://172.16.55.185:9200/itcast
{
    "settings": {
        "index": {
            "number_of_shards": "2",
```

```
            "number_of_replicas": "0"
        }
    },
    "mappings": {
        "person": {
            "properties": {
                "name": {
                    "type": "text"
                },
                "age": {
                    "type": "integer"
                },
                "mail": {
                    "type": "keyword"
                },
                "hobby": {
                    "type": "text"
                }
            }
        }
    }
}
```

查看映射：

```
GET http://172.16.55.185:9200/itcast/_mapping
```

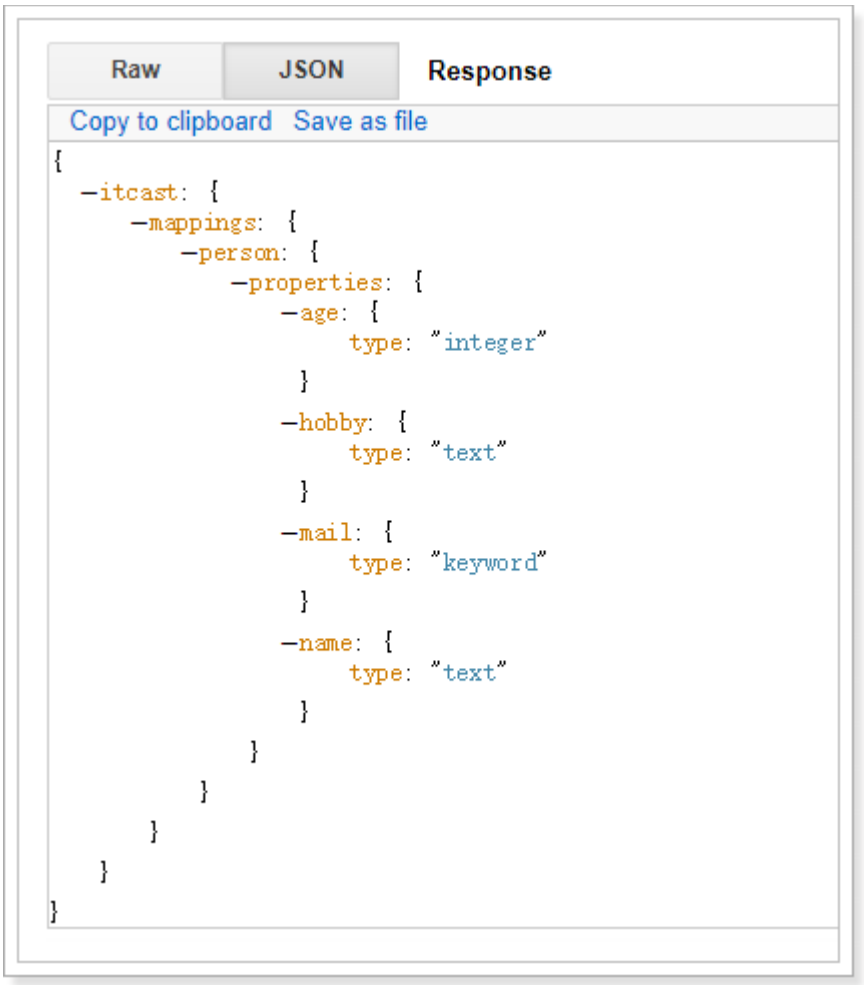

插入数据：

```
POST http://172.16.55.185:9200/itcast/_bulk

{"index":{"_index":"itcast","_type":"person"}}
{"name":"张三","age": 20,"mail": "111@qq.com","hobby":"羽毛球、乒乓球、足球"}
{"index":{"_index":"itcast","_type":"person"}}
{"name":"李四","age": 21,"mail": "222@qq.com","hobby":"羽毛球、乒乓球、足球、篮球"}
{"index":{"_index":"itcast","_type":"person"}}
{"name":"王五","age": 22,"mail": "333@qq.com","hobby":"羽毛球、篮球、游泳、听音乐"}
{"index":{"_index":"itcast","_type":"person"}}
{"name":"赵六","age": 23,"mail": "444@qq.com","hobby":"跑步、游泳"}
{"index":{"_index":"itcast","_type":"person"}}
{"name":"孙七","age": 24,"mail": "555@qq.com","hobby":"听音乐、看电影"}

```

查询 2 个分片中用的 2 个. 5 命中. 耗时 0.002 秒

_index	_type	_id	_score ▼	name	age	mail	hobby
itcast	person	C7OM_2cB9cFOnF3ux7uD	1	孙七	24	555@qq.com	听音乐、看电影
itcast	person	B7OM_2cB9cFOnF3ux7uD	1	张三	20	111@qq.com	羽毛球、乒乓球、足球
itcast	person	CLOM_2cB9cFOnF3ux7uD	1	李四	21	222@qq.com	羽毛球、乒乓球、足球、篮球
itcast	person	CbOM_2cB9cFOnF3ux7uD	1	王五	22	333@qq.com	羽毛球、篮球、游泳、听音乐
itcast	person	CrOM_2cB9cFOnF3ux7uD	1	赵六	23	444@qq.com	跑步、游泳

测试搜索：

```
POST http://172.16.55.185:9200/itcast/person/_search
{
    "query" : {
        "match" : {
            "hobby" : "音乐"
        }
    }
}
```

```
{
  took: 9
  timed_out: false
  _shards: {
    total: 2
    successful: 2
    skipped: 0
    failed: 0
  }
  hits: {
    total: 2
    max_score: 2.1845279
    hits: [2]
      0: {
        _index: "itcast"
        _type: "person"
        _id: "CbOM_2cB9cFOnF3ux7uD"
        _score: 2.1845279
        _source: {
          name: "王五"
          age: 22
          mail: "333@qq.com"
          hobby: "羽毛球、篮球、游泳、听音乐"
        }
      }
      1: {
        _index: "itcast"
        _type: "person"
        _id: "C7OM_2cB9cFOnF3ux7uD"
        _score: 0.5753642
        _source: {
          name: "孙七"
          age: 24
          mail: "555@qq.com"
          hobby: "听音乐、看电影"
        }
      }
  }
}
```


3.7、结构化查询

3.7.1、term查询

`term`主要用于精确匹配哪些值，比如数字，日期，布尔值或`not_analyzed`的字符串(未经分析的文本数据类型)：

```
    { "term": { "age":    26           }}
    { "term": { "date":   "2014-09-01" }}
    { "term": { "public": true         }}
    { "term": { "tag":    "full_text"  }}
```

示例：

```
POST http://172.16.55.185:9200/itcast/person/_search
{
    "query" : {
        "term" : {
            "age" : 20
        }
    }
}
```

3.7.2、terms查询

`terms` 跟 `term` 有点类似，但 `terms` 允许指定多个匹配条件。 如果某个字段指定了多个值，那么文档需要一起去做匹配：

```
{
    "terms": {
        "tag": [ "search", "full_text", "nosql" ]
        }
}
```

示例：

```
POST http://172.16.55.185:9200/itcast/person/_search
{
    "query" : {
        "terms" : {
            "age" : [20,21]
        }
    }
}
```


```
-hits: {
    total: 2
    max_score: 1
   -hits: [2]
      -0:   {
            _index: "itcast"
            _type: "person"
            _id: "B7OM_2cB9cFOnF3ux7uD"
            _score: 1
           -_source: {
                name: "张三"
                age: 20
                mail: "111@qq.com"
                hobby: "羽毛球、乒乓球、足球"
            }
        }
      -1:   {
            _index: "itcast"
            _type: "person"
            _id: "CLOM_2cB9cFOnF3ux7uD"
            _score: 1
           -_source: {
                name: "李四"
                age: 21
                mail: "222@qq.com"
                hobby: "羽毛球、乒乓球、足球、篮球"
            }
        }
  }
}
```


3.7.3、range查询

`range` 过滤允许我们按照指定范围查找一批数据：

```
{
    "range": {
        "age": {
            "gte":  20,
            "lt":   30
        }
    }
}
```

范围操作符包含：

`gt` :: 大于

`gte` :: 大于等于

`lt` :: 小于

`lte` :: 小于等于

示例：

```
POST http://172.16.55.185:9200/itcast/person/_search
{
    "query": {
        "range": {
            "age": {
                "gte": 20,
                "lte": 22
            }
        }
    }
}
```

```
-hits: {
    total: 3
    max_score: 1
   -hits: [3]
      -0:   {
            _index: "itcast"
            _type: "person"
            _id: "B7OM_2cB9cFOnF3ux7uD"
            _score: 1
           -_source: {
                name: "张三"
                age: 20
                mail: "111@qq.com"
                hobby: "羽毛球、乒乓球、足球"
            }
       }
      -1:   {
            _index: "itcast"
            _type: "person"
            _id: "CLOM_2cB9cFOnF3ux7uD"
            _score: 1
           -_source: {
                name: "李四"
                age: 21
                mail: "222@qq.com"
                hobby: "羽毛球、乒乓球、足球、篮球"
            }
       }
      -2:   {
            _index: "itcast"
            _type: "person"
            _id: "CbOM_2cB9cFOnF3ux7uD"
            _score: 1
           -_source: {
                name: "王五"
                age: 22
                mail: "333@qq.com"
                hobby: "羽毛球、篮球、游泳、听音乐"
            }
```


3.7.4、exists 查询

`exists` 查询可以用于查找文档中是否包含指定字段或没有某个字段，类似于SQL语句中的`IS_NULL`条件

```
{
    "exists":   {
        "field":    "title"
    }
}
```

这两个查询只是针对已经查出一批数据来，但是想区分出某个字段是否存在的时候使用。

示例：

```
POST http://172.16.55.185:9200/haoke/user/_search
{
    "query": {
        "exists": {  #必须包含
            "field": "card"
        }
    }
}

```

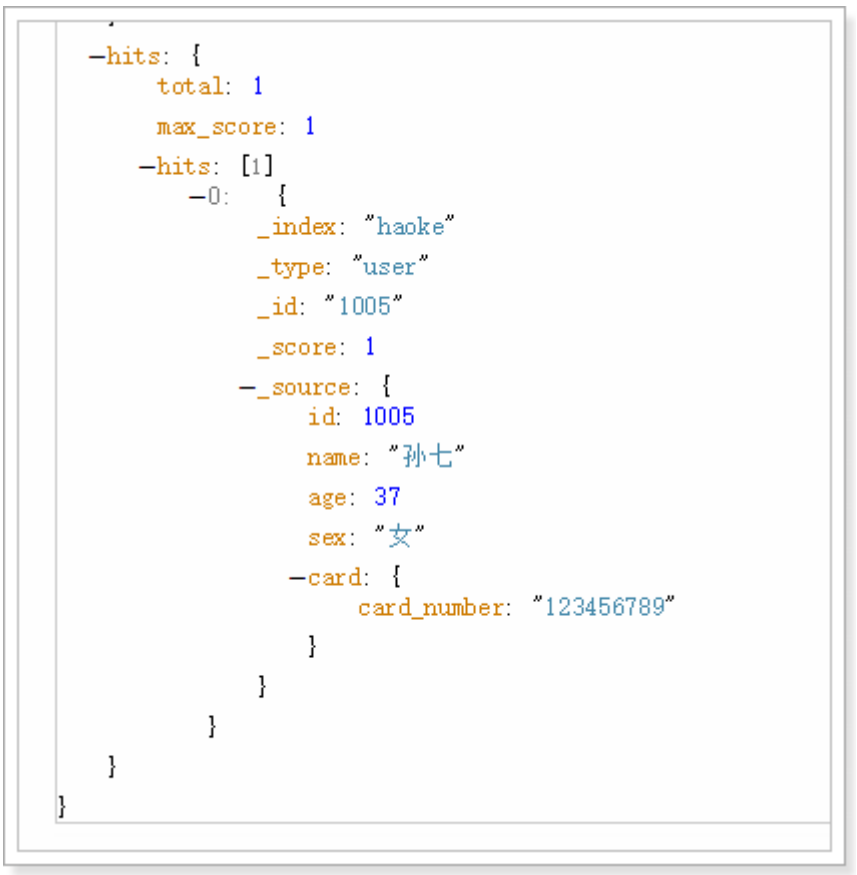

3.6.5、match查询

`match` 查询是一个标准查询，不管你需要全文本查询还是精确查询基本上都要用到它。

如果你使用 `match` 查询一个全文本字段，它会在真正查询之前用分析器先分析 `match` 一下查询字符：

```
{
    "match": {
        "tweet": "About Search"
    }
}
```

如果用 `match` 下指定了一个确切值，在遇到数字，日期，布尔值或者 `not_analyzed` 的字符串时，它将为你搜索你给定的值：

```
{ "match": { "age":    26           }}
{ "match": { "date":   "2014-09-01" }}
{ "match": { "public": true         }}
{ "match": { "tag":    "full_text"  }}
```

3.7.6、bool查询

`bool` 查询可以用来合并多个条件查询结果的布尔逻辑，它包含一下操作符：

`must` :: 多个查询条件的完全匹配,相当于 `and` 。

`must_not` :: 多个查询条件的相反匹配，相当于 `not` 。

`should` :: 至少有一个查询条件匹配, 相当于 `or` 。

这些参数可以分别继承一个查询条件或者一个查询条件的数组：

```
{
    "bool": {
        "must":     { "term": { "folder": "inbox" }},
        "must_not": { "term": { "tag":    "spam"  }},
        "should": [
                    { "term": { "starred": true   }},
                    { "term": { "unread":  true   }}
        ]
    }
}
```

3.8、过滤查询

前面讲过结构化查询，Elasticsearch也支持过滤查询，如term、range、match等。

示例：查询年龄为20岁的用户。

```
POST http://172.16.55.185:9200/itcast/person/_search
{
    "query": {
        "bool": {
            "filter": {
                "term": {
                    "age": 20
                }
            }
        }
    }
}
```

结果：

> 查询和过滤的对比

- 一条过滤语句会询问每个文档的字段值是否包含着特定值。
- 查询语句会询问每个文档的字段值与特定值的匹配程度如何。
  - 一条查询语句会计算每个文档与查询语句的相关性，会给出一个相关性评分 _score，并且 按照相关性对匹配到的文档进行排序。 这种评分方式非常适用于一个没有完全配置结果的全文本搜索。
- 一个简单的文档列表，快速匹配运算并存入内存是十分方便的， 每个文档仅需要1个字节。这些缓存的过滤结果集与后续请求的结合使用是非常高效的。
- 查询语句不仅要查找相匹配的文档，还需要计算每个文档的相关性，所以一般来说查询语句要比 过滤语句更耗时，并且查询结果也不可缓存。

> 建议：
>
> 做精确匹配搜索时，最好用过滤语句，因为过滤语句可以缓存数据。

4、中文分词

4.1、什么是分词

分词就是指将一个文本转化成一系列单词的过程，也叫文本分析，在Elasticsearch中称之为Analysis。

举例：我是中国人 --> 我/是/中国人

4.2、分词api

> 指定分词器进行分词

```
POST http://172.16.55.185:9200/_analyze
{
     "analyzer":"standard",
     "text":"hello world"
}
```

结果：

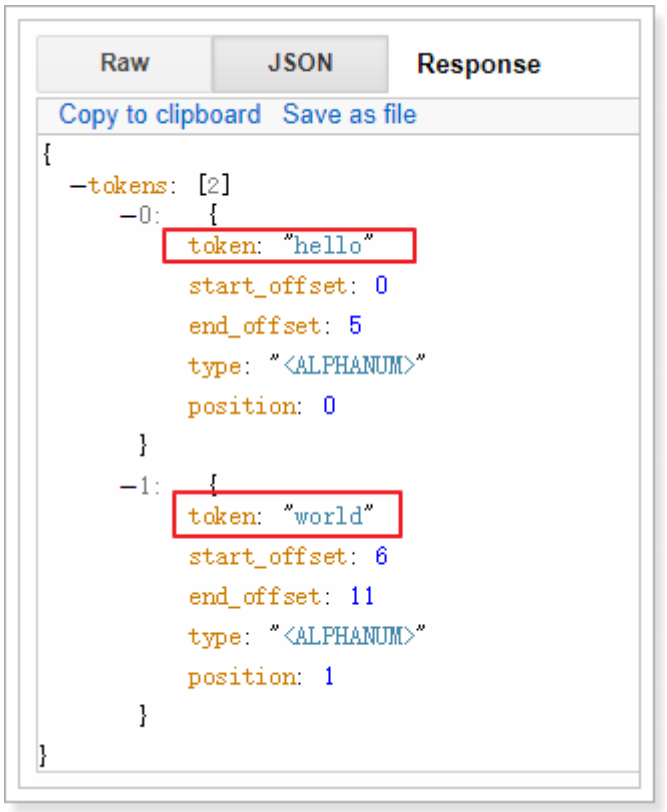

在结果中不仅可以看出分词的结果，还返回了该词在文本中的位置。

> 指定索引分词

```
POST http://172.16.55.185:9200/itcast/_analyze
{
    "analyzer": "standard",
    "field": "hobby",
    "text": "听音乐"
}
```

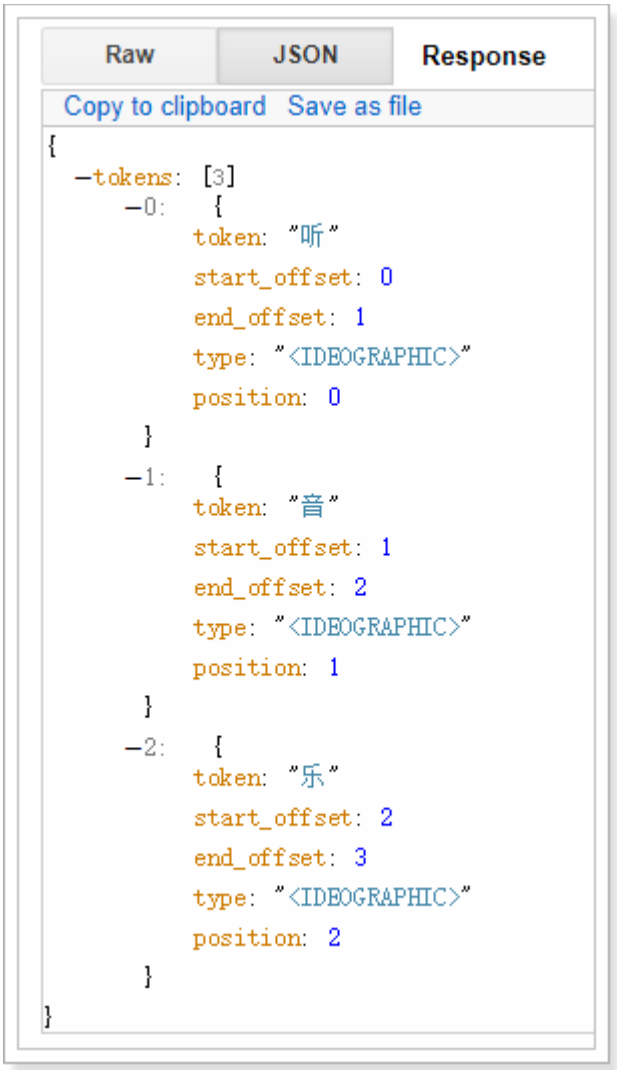

4.3、内置分词

4.3.1、Standard

> Standard 标准分词，按单词切分，并且会转化成小写

```
POST http://172.16.55.185:9200/_analyze
{
    "analyzer": "standard",
    "text": "A man becomes learned by asking questions."
}
```

结果：

```
{
    "tokens": [
        {
            "token": "a",
            "start_offset": 0,
            "end_offset": 1,
            "type": "<ALPHANUM>",
            "position": 0
```

```
        },
        {
            "token": "man",
            "start_offset": 2,
            "end_offset": 5,
            "type": "<ALPHANUM>",
            "position": 1
        },
        {
            "token": "becomes",
            "start_offset": 6,
            "end_offset": 13,
            "type": "<ALPHANUM>",
            "position": 2
        },
        {
            "token": "learned",
            "start_offset": 14,
            "end_offset": 21,
            "type": "<ALPHANUM>",
            "position": 3
        },
        {
            "token": "by",
            "start_offset": 22,
            "end_offset": 24,
            "type": "<ALPHANUM>",
            "position": 4
        },
        {
            "token": "asking",
            "start_offset": 25,
            "end_offset": 31,
            "type": "<ALPHANUM>",
            "position": 5
        },
        {
            "token": "questions",
            "start_offset": 32,
            "end_offset": 41,
            "type": "<ALPHANUM>",
            "position": 6
        }
    ]
}
```


4.3.2、Simple

> Simple分词器，按照非单词切分，并且做小写处理

```
POST http://172.16.55.185:9200/_analyze
{
    "analyzer": "simple",
    "text": "If the document doesn't already exist"
}
```

结果：

```
{
    "tokens": [
        {
            "token": "if",
            "start_offset": 0,
            "end_offset": 2,
            "type": "word",
            "position": 0
        },
        {
            "token": "the",
            "start_offset": 3,
            "end_offset": 6,
            "type": "word",
            "position": 1
        },
        {
            "token": "document",
            "start_offset": 7,
            "end_offset": 15,
            "type": "word",
            "position": 2
        },
        {
            "token": "doesn",
            "start_offset": 16,
            "end_offset": 21,
            "type": "word",
            "position": 3
        },
        {
            "token": "t",
            "start_offset": 22,
            "end_offset": 23,
            "type": "word",
            "position": 4
        },
        {
            "token": "already",
            "start_offset": 24,
            "end_offset": 31,
            "type": "word",
            "position": 5
        },
```

```
        {
            "token": "exist",
            "start_offset": 32,
            "end_offset": 37,
            "type": "word",
            "position": 6
        }
    ]
}
```

4.3.3、Whitespace

Whitespace是按照空格切分。

示例：

```
POST http://172.16.55.185:9200/_analyze
{
    "analyzer": "whitespace",
    "text": "If the document doesn't already exist"
}
```

结果：

```
{
    "tokens": [
        {
            "token": "If",
            "start_offset": 0,
            "end_offset": 2,
            "type": "word",
            "position": 0
        },
        {
            "token": "the",
            "start_offset": 3,
            "end_offset": 6,
            "type": "word",
            "position": 1
        },
        {
            "token": "document",
            "start_offset": 7,
            "end_offset": 15,
            "type": "word",
            "position": 2
        },
        {
            "token": "doesn't",
            "start_offset": 16,
            "end_offset": 23,
            "type": "word",
```

```
            "position": 3
        },
        {
            "token": "already",
            "start_offset": 24,
            "end_offset": 31,
            "type": "word",
            "position": 4
        },
        {
            "token": "exist",
            "start_offset": 32,
            "end_offset": 37,
            "type": "word",
            "position": 5
        }
    ]
}
```

4.3.4、Stop

Stop分词器，是去除Stop Word语气助词，如the、an等。

```
POST http://172.16.55.185:9200/_analyze
{
    "analyzer": "stop",
    "text": "If the document doesn't already exist"
}
```

结果：

```
{
    "tokens": [
        {
            "token": "document",
            "start_offset": 7,
            "end_offset": 15,
            "type": "word",
            "position": 2
        },
        {
            "token": "doesn",
            "start_offset": 16,
            "end_offset": 21,
            "type": "word",
            "position": 3
        },
        {
            "token": "t",
            "start_offset": 22,
            "end_offset": 23,
            "type": "word",
```

```
            "position": 4
        },
        {
            "token": "already",
            "start_offset": 24,
            "end_offset": 31,
            "type": "word",
            "position": 5
        },
        {
            "token": "exist",
            "start_offset": 32,
            "end_offset": 37,
            "type": "word",
            "position": 6
        }
    ]
}
```

4.3.5、Keyword

> Keyword分词器，意思是传入就是关键词，不做分词处理。

```
POST http://172.16.55.185:9200/_analyze
{
    "analyzer": "keyword",
    "text": "If the document doesn't already exist"
}
```

结果：

```
{
    "tokens": [
        {
            "token": "If the document doesn't already exist",
            "start_offset": 0,
            "end_offset": 37,
            "type": "word",
            "position": 0
        }
    ]
}
```

4.4、中文分词

中文分词的难点在于，在汉语中没有明显的词汇分界点，如在英语中，空格可以作为分隔符，如果分隔不正确就会造成歧义。

如：

我/爱/炒肉丝

我/爱/炒/肉丝

常用中文分词器，IK、jieba、THULAC等，推荐使用IK分词器。

> IK Analyzer是一个开源的，基于java语言开发的轻量级的中文分词工具包。从2006年12月推出1.0版开始，IKAnalyzer已经推出了3个大版本。最初，它是以开源项目Luence为应用主体的，结合词典分词和文法分析算法的中文分词组件。新版本的IK Analyzer 3.0则发展为面向Java的公用分词组件，独立于Lucene项目，同时提供了对Lucene的默认优化实现。
>
> 采用了特有的"正向迭代最细粒度切分算法"，具有80万字/秒的高速处理能力 采用了多子处理器分析模式，支持：英文字母（IP地址、Email、URL）、数字（日期，常用中文数量词，罗马数字，科学计数法），中文词汇（姓名、地名处理）等分词处理。 优化的词典存储，更小的内存占用。

IK分词器 Elasticsearch插件地址：https://github.com/medcl/elasticsearch-analysis-ik

```
#安装方法：将下载到的elasticsearch-analysis-ik-6.5.4.zip解压到/elasticsearch/plugins/ik目录下即可。

#如果使用docker运行
docker cp /tmp/elasticsearch-analysis-ik-6.5.4.zip elasticsearch:/usr/share/elasticsearch/plugins/
#进入容器
docker exec -it elasticsearch /bin/bash
mkdir /usr/share/elasticsearch/plugins/ik
cd /usr/share/elasticsearch/plugins/ik
unzip elasticsearch-analysis-ik-6.5.4.zip

#重启容器即可
docker restart elasticsearch
```

测试：

```
POST http://172.16.55.185:9200/_analyze
{
    "analyzer": "ik_max_word",
    "text": "我是中国人"
}
```

结果：

```
{
    "tokens": [
        {
            "token": "我",
            "start_offset": 0,
            "end_offset": 1,
            "type": "CN_CHAR",
            "position": 0
        },
        {
            "token": "是",
            "start_offset": 1,
```

```
            "end_offset": 2,
            "type": "CN_CHAR",
            "position": 1
        },
        {
            "token": "中国人",
            "start_offset": 2,
            "end_offset": 5,
            "type": "CN_WORD",
            "position": 2
        },
        {
            "token": "中国",
            "start_offset": 2,
            "end_offset": 4,
            "type": "CN_WORD",
            "position": 3
        },
        {
            "token": "国人",
            "start_offset": 3,
            "end_offset": 5,
            "type": "CN_WORD",
            "position": 4
        }
    ]
}
```

可以看到，已经对中文进行了分词。